Tugas Machine Learning dengan Orange:
Klasifikasi, Regresi dan Clustering

Sabili Putra Kirana

20124096

C1.24

Machine Learning

A. Klasifikasi Dataset Titanic

Tujuan

Pada bagian ini saya melakukan klasifikasi pada dataset Titanic menggunakan aplikasi Orange. Target yang diprediksi adalah Survived, yaitu apakah penumpang selamat atau tidak. Tujuan dari analisis ini adalah membandingkan beberapa model klasifikasi dan menentukan model terbaik berdasarkan hasil evaluasi.

Dataset yang digunakan

Dataset yang digunakan adalah titanic_train.csv.
Target yang digunakan adalah Survived.

Fitur yang digunakan:

- Pclass
- Sex
- Age
- SibSp
- Parch
- Fare
- Embarked

Kolom yang tidak digunakan sebagai fitur:

- PassengerId
- Name
- Ticket
- Cabin

Workflow di Orange

Workflow yang saya gunakan pada Orange adalah:

File → Select Columns → Preprocess → Train Test Split → Model → Test and Score → Confusion Matrix

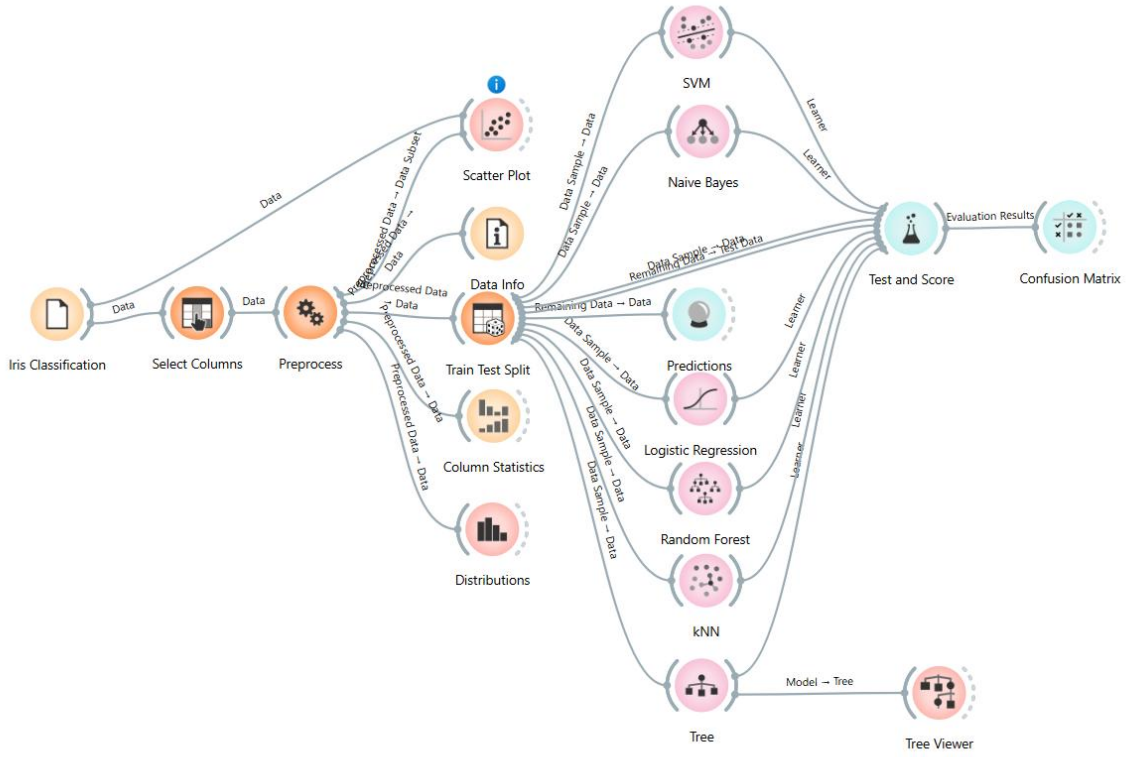

Gambar 1. *Workflow klasifikasi dataset Titanic pada Orange*

Pengaturan data

Pada tahap **Select Columns**, saya menetapkan **Survived** sebagai target. Kolom yang dipakai sebagai fitur adalah Pclass, Sex, Age, SibSp, Parch, Fare, dan Embarked. Kolom PassengerId, Name, Ticket, dan Cabin tidak digunakan karena tidak terlalu relevan sebagai fitur utama.

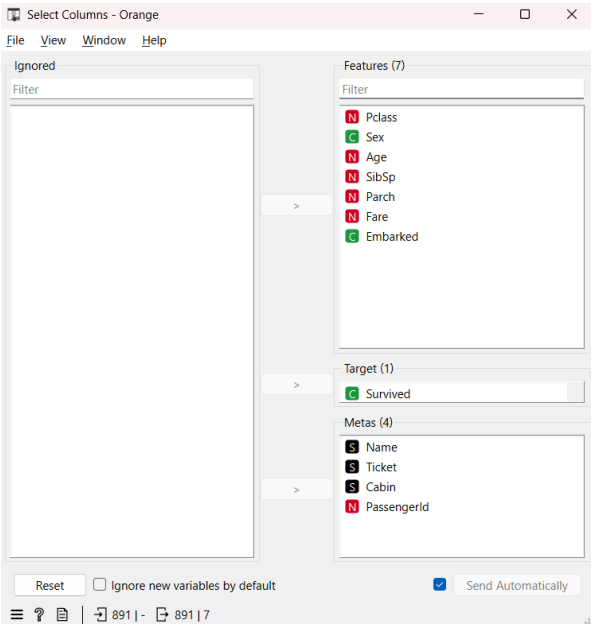

Gambar 2. *Pengaturan Select Columns pada dataset Titanic*

Pada tahap Preprocess, data diproses agar siap digunakan untuk pemodelan, terutama untuk menangani nilai yang kosong dan menyesuaikan tipe data agar bisa dibaca model dengan baik.

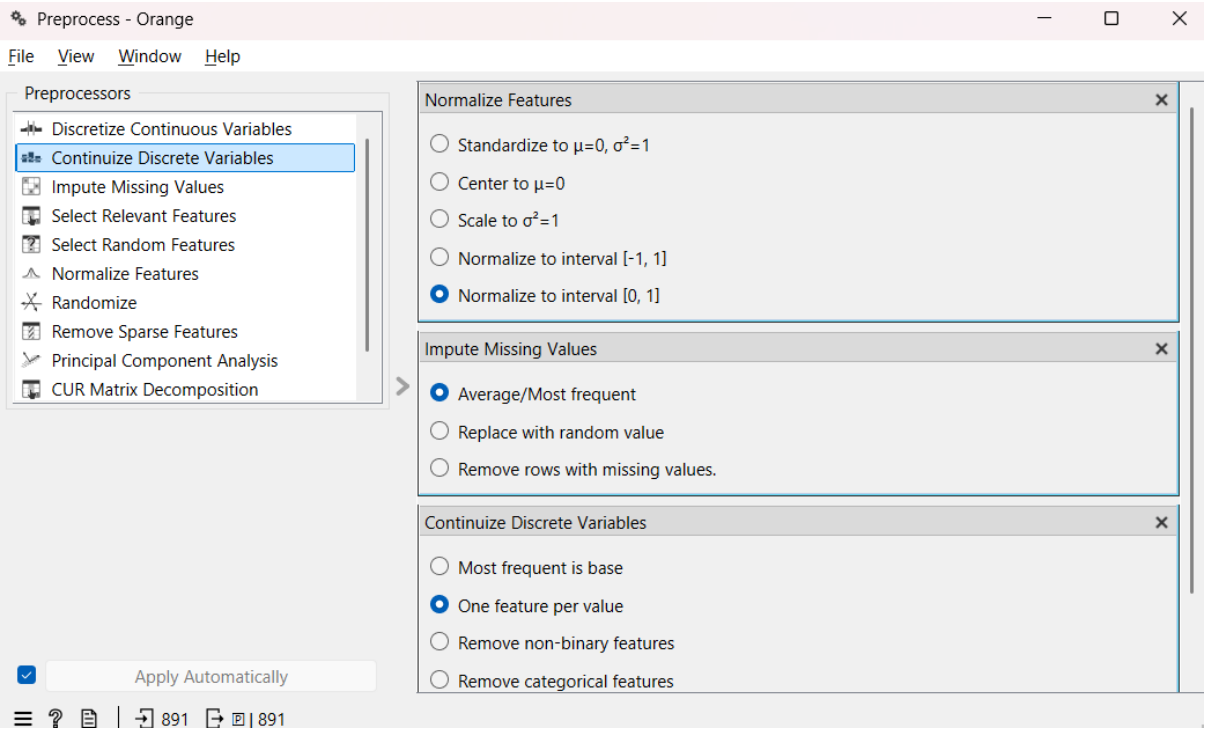

Gambar 3. *Pengaturan Preprocess pada dataset Titanic*

Setelah itu, data dibagi menjadi data latih dan data uji menggunakan Train Test Split. Data latih digunakan untuk melatih model, sedangkan data uji digunakan untuk menguji performa model.

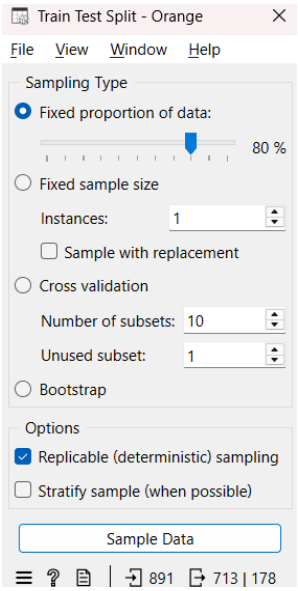

Gambar 4. *Pembagian data train dan test pada Orange*

Model yang diuji

Model klasifikasi yang saya gunakan adalah:

- Tree
- kNN
- Logistic Regression
- Naive Bayes
- SVM
- Random Forest

Model-model tersebut dibandingkan menggunakan widget Test and Score.

Hasil Test and Score

Berikut adalah hasil evaluasi model klasifikasi pada dataset Titanic.

Evaluation results for target (None, show average over classe

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.800	0.803	0.801	0.801	0.803	0.568
kNN	0.814	0.798	0.798	0.798	0.798	0.564
Logistic Regression	0.876	0.809	0.808	0.808	0.809	0.585
Naive Bayes	0.868	0.815	0.815	0.817	0.815	0.604
SVM	0.843	0.787	0.774	0.791	0.787	0.526
Random Forest	0.872	0.820	0.819	0.819	0.820	0.608

Gambar 5. *Hasil Test and Score klasifikasi Titanic*

Berdasarkan hasil evaluasi, diperoleh nilai sebagai berikut:

Model	AUC	CA	F1	Precision	Recall	MCC
Tree	0.800	0.803	0.801	0.801	0.803	0.568
kNN	0.814	0.798	0.798	0.798	0.798	0.564
Logistic Regression	0.876	0.809	0.808	0.808	0.809	0.585
Naive Bayes	0.868	0.815	0.815	0.817	0.815	0.604
SVM	0.843	0.787	0.774	0.791	0.787	0.526
Random Forest	0.872	0.820	0.819	0.819	0.820	0.608

Dari tabel di atas, Logistic Regression memiliki nilai AUC tertinggi, yaitu 0.876. Namun, Random Forest memiliki hasil terbaik secara keseluruhan karena unggul pada CA, F1, Precision, Recall, dan MCC.

Model terbaik

Walaupun Logistic Regression unggul pada AUC, saya memilih Random Forest sebagai model terbaik karena performanya paling stabil dan paling tinggi pada sebagian besar metrik evaluasi. Model ini memiliki:

- CA = 0.820
- F1 = 0.819
- Precision = 0.819
- Recall = 0.820
- MCC = 0.608

Jadi, secara umum Random Forest adalah model terbaik untuk klasifikasi dataset Titanic pada percobaan ini.

Confusion Matrix

Untuk melihat hasil prediksi lebih detail, saya menggunakan Confusion Matrix pada model terbaik, yaitu Random Forest.

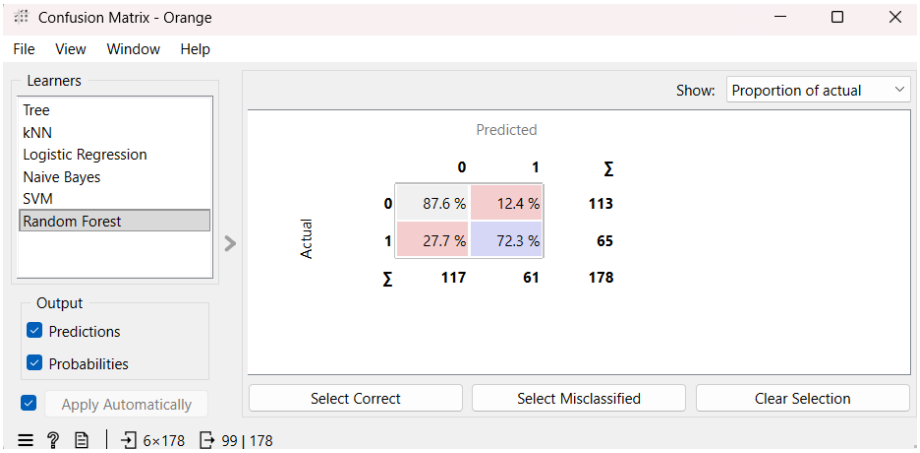

Gambar 6. *Confusion Matrix model Random Forest*

Berdasarkan confusion matrix, terdapat 14 penumpang yang diprediksi selamat, padahal sebenarnya tidak selamat. Nilai ini menunjukkan jumlah false positive pada model Random Forest.

Jawaban pertanyaan

a. **Which model had the highest AUC?**

Model dengan AUC tertinggi adalah Logistic Regression dengan nilai 0.876.

b. **Which model had the highest F1?**

Model dengan F1 tertinggi adalah Random Forest dengan nilai 0.819.

c. **Are these the same model? Which would you choose and why?**

Tidak, modelnya berbeda. Logistic Regression memiliki AUC tertinggi, sedangkan Random Forest memiliki F1 tertinggi. Saya memilih Random Forest karena memiliki performa terbaik secara keseluruhan pada sebagian besar metrik evaluasi.

d. **How many passengers did the best model incorrectly predict as survived when they did not?**

Jumlahnya adalah 14 penumpang.

B. Regresi Dataset Housing

Tujuan

Pada bagian ini saya melakukan analisis regresi menggunakan dataset Housing pada aplikasi Orange. Target yang diprediksi adalah MEDV. Tujuan analisis ini adalah membandingkan beberapa model regresi dan menentukan model terbaik berdasarkan hasil evaluasi.

Dataset yang digunakan

Dataset yang digunakan adalah **housing.csv**.
Target yang digunakan adalah **MEDV**.

Fitur yang digunakan:

- RM
- LSTAT
- PTRATIO

Workflow di Orange

Workflow yang saya gunakan pada Orange adalah:

File → Select Columns → Preprocess → Train/Test Split → Model → Test and Score → Predictions

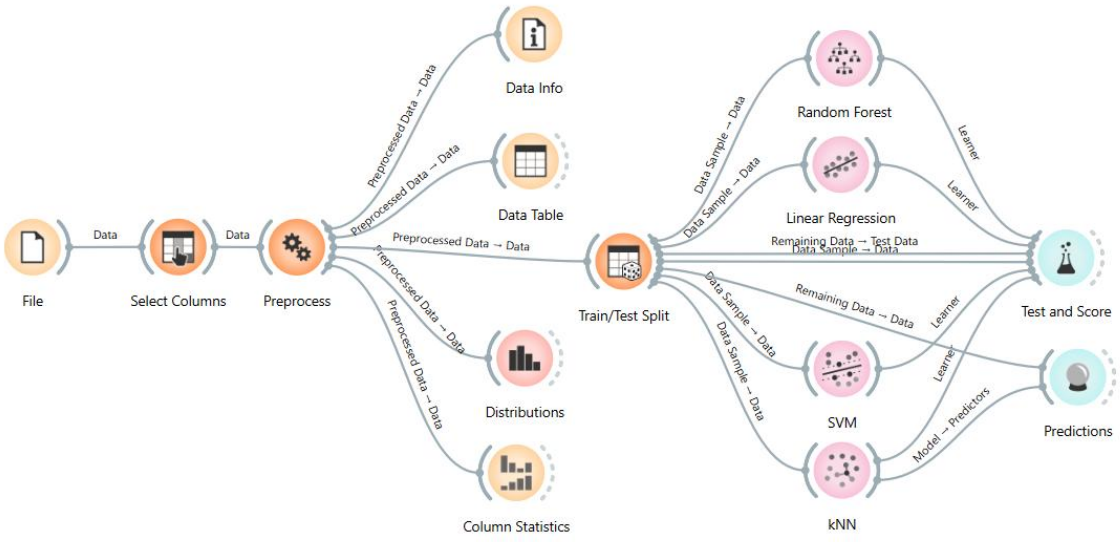

Gambar 7. *Workflow regresi dataset Housing pada Orange*

Pengaturan data

Pada tahap **Select Columns**, saya menetapkan **MEDV** sebagai target, sedangkan **RM, LSTAT,** dan **PTRATIO** digunakan sebagai fitur.

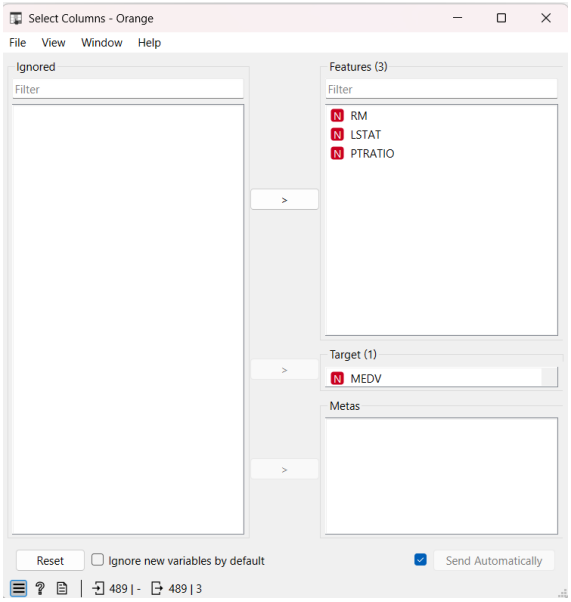

Gambar 8. *Pengaturan Select Columns pada dataset Housing*

Pada tahap Preprocess, data diproses agar siap digunakan untuk pemodelan. Setelah itu, data dibagi menjadi data latih dan data uji menggunakan Train/Test Split.

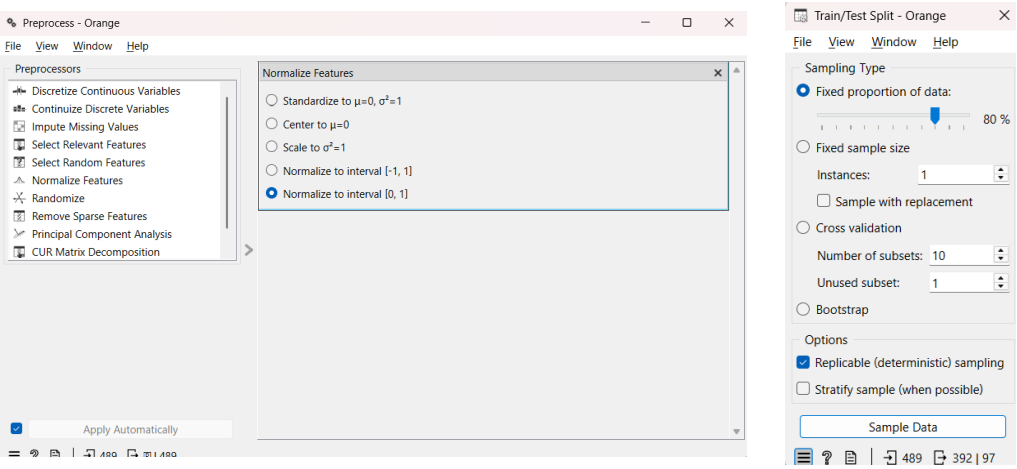

Gambar 9. *Pengaturan Preprocess dan pembagian data train-test*

Model yang diuji

Model regresi yang saya gunakan adalah:

- Random Forest
- Linear Regression
- kNN
- SVM

Hasil Test and Score

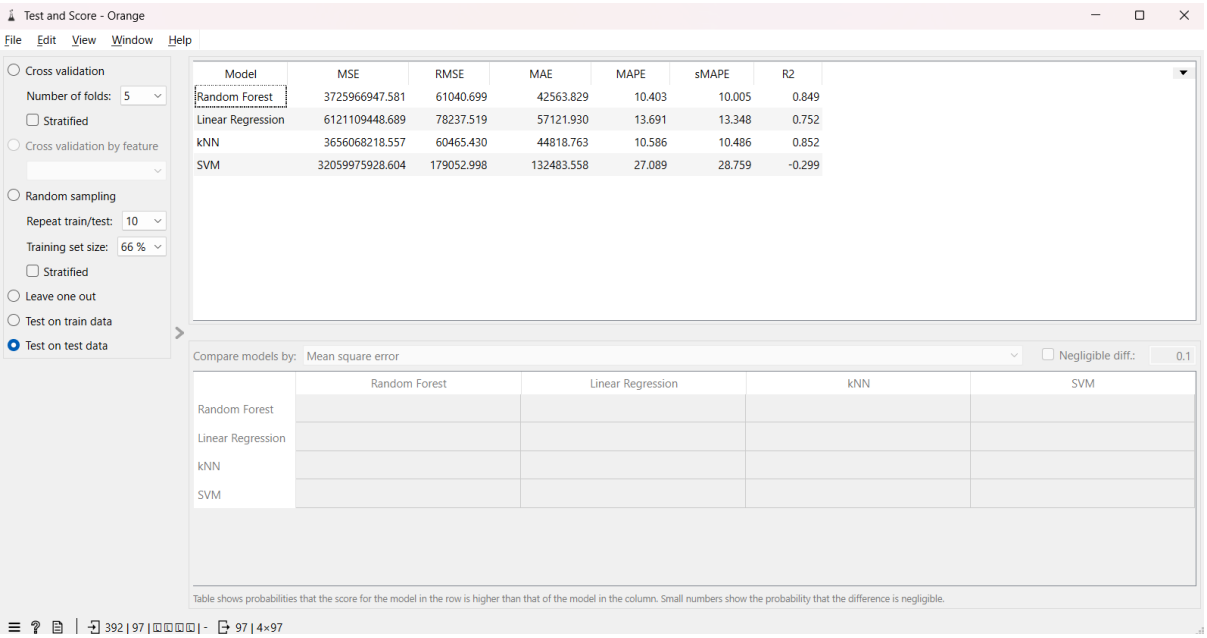

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Random Forest	3725966947.581	61040.699	42563.829	10.403	10.005	0.849
Linear Regression	6121109448.689	78237.519	57121.930	13.691	13.348	0.752
kNN	3656068218.557	60465.430	44818.763	10.586	10.486	0.852
SVM	32059975928.604	179052.998	132483.558	27.089	28.759	-0.299

Gambar 10. Hasil Test and Score regresi Housing

Dari hasil tersebut, terlihat bahwa:

- Random Forest memiliki MAE paling rendah, yaitu 42563.829
- kNN memiliki RMSE paling rendah, yaitu 60465.430
- kNN juga memiliki R^2 tertinggi, yaitu 0.852
- SVM memiliki performa paling rendah karena nilai error sangat besar dan R^2 bernilai negatif

Analisis Hasil

Pada regresi, model yang baik adalah model dengan nilai MSE, RMSE, dan MAE yang kecil, serta nilai R^2 yang besar.

Berdasarkan hasil yang diperoleh, Random Forest unggul pada metrik MAE, yang berarti model ini memiliki rata-rata kesalahan absolut paling kecil. Namun, kNN unggul pada RMSE dan R^2, sehingga model ini lebih baik dalam menjelaskan variasi data dan memberikan prediksi yang lebih baik secara umum.

Sementara itu, Linear Regression masih memberikan hasil yang cukup baik, tetapi performanya masih berada di bawah Random Forest dan kNN. Model SVM menunjukkan hasil yang kurang baik karena memiliki error yang sangat besar dan nilai R^2 negatif, yang menandakan model tidak mampu mengikuti pola data dengan baik.

Model Terbaik

Pada bagian regresi ini, model terbaik secara umum adalah kNN, karena memiliki RMSE paling rendah dan R^2 tertinggi. Namun, jika dilihat dari metrik MAE, model terbaik adalah Random Forest.

Dengan demikian, dapat disimpulkan bahwa:

- Random Forest unggul pada MAE
- kNN unggul pada RMSE dan R^2
- Secara umum, kNN dipilih sebagai model terbaik

Predictions

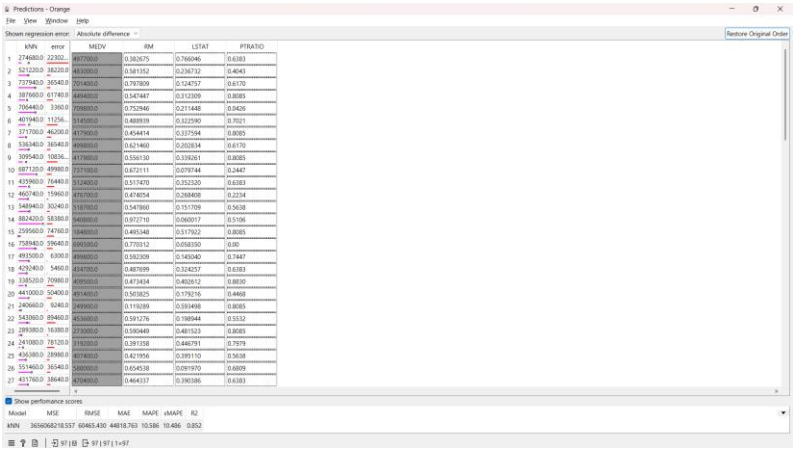

	kNN	error	MEDV	RM	LSTAT	PTRATIO
1	274680.0	22302...	497700.0	0.382675	0.766046	0.6383
2	521220.0	38220.0	483000.0	0.581352	0.236732	0.4043
3	737940.0	36540.0	701400.0	0.797809	0.124757	0.6170
4	387660.0	61740.0	449400.0	0.547447	0.312309	0.8085
5	706440.0	3360.0	709800.0	0.752846	0.211448	0.0426
6	401940.0	11256...	514500.0	0.488939	0.322590	0.7021
7	371700.0	46200.0	417900.0	0.454414	0.337594	0.8085
8	536340.0	36040.0	499800.0	0.621460	0.202834	0.6170
9	309540.0	10836...	417900.0	0.356130	0.339261	0.8085
10	687120.0	49880.0	737100.0	0.672111	0.079744	0.2447
11	435960.0	76440.0	512400.0	0.517470	0.352320	0.6383
12	460740.0	15960.0	476700.0	0.474054	0.268408	0.2234
13	548940.0	30240.0	518700.0	0.547860	0.151709	0.5638
14	882420.0	58380.0	940800.0	0.972710	0.060017	0.5106
15	259560.0	74760.0	334800.0	0.495348	0.517922	0.8085
16	758940.0	596400.0	1355400.0	0.770512	0.058350	0.00
17	493500.0	6300.0	499800.0	0.592309	0.145040	0.7447
18	429240.0	5460.0	434700.0	0.487699	0.324257	0.6383
19	338520.0	70980.0	409500.0	0.473434	0.402612	0.8830
20	441000.0	50400.0	491400.0	0.503825	0.179216	0.4468
21	240660.0	9240.0	249900.0	0.119089	0.593498	0.8085
22	543060.0	89460.0	453600.0	0.591276	0.198944	0.5532
23	289380.0	16380.0	273000.0	0.180449	0.481523	0.8085
24	241080.0	78120.0	319200.0	0.281358	0.446791	0.7979
25	436380.0	28980.0	407400.0	0.421956	0.395110	0.5638
26	551460.0	36540.0	588000.0	0.654538	0.091970	0.6809
27	431760.0	38640.0	470400.0	0.464337	0.390386	0.6383

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
kNN	3656068218.557	60465.430	44818.763	10.586	10.486	0.852

Berdasarkan hasil Predictions, baris dengan error terbesar terdapat pada baris pertama. Pada data tersebut, model memprediksi nilai **274680.0**, sedangkan nilai aktualnya adalah **497700.0**, sehingga error absolutnya sebesar **223020.0**.

Jawaban Pertanyaan

a. Which model had the lowest MAE? By how much?

Model dengan MAE terendah adalah Random Forest, yaitu 42563.829.

Selisihnya dengan model terbaik kedua, yaitu kNN (44818.763), adalah:

44818.763 - 42563.829 = 2254.934

Jadi, Random Forest lebih baik sebesar **2254.934** pada metrik MAE dibandingkan kNN.

b. Which model had the best R^2?

Model dengan **R^2 terbaik** adalah **kNN**, yaitu **0.852**.

c. Open Predictions for your best model. Find the row with the largest error. Predicted vs actual?

Pada baris dengan error terbesar, nilai predicted adalah 274680.0, sedangkan nilai actual adalah 497700.0.

d. What does this suggest about what the model struggles with?

Hal ini menunjukkan bahwa model masih kesulitan memprediksi beberapa data yang memiliki pola cukup berbeda dari data tetangga terdekatnya. Karena kNN bergantung pada kedekatan antar data, model ini dapat menghasilkan error besar pada data tertentu.

C. Clustering Dataset Iris

Tujuan

Pada bagian ini saya melakukan analisis clustering pada dataset Iris menggunakan aplikasi Orange. Tujuan analisis ini adalah mengelompokkan data bunga Iris berdasarkan kemiripan karakteristiknya tanpa menggunakan target label.

Dataset yang Digunakan

Dataset yang digunakan adalah dataset Iris. Fitur yang digunakan dalam proses clustering adalah atribut numerik pada dataset Iris.

Workflow di Orange

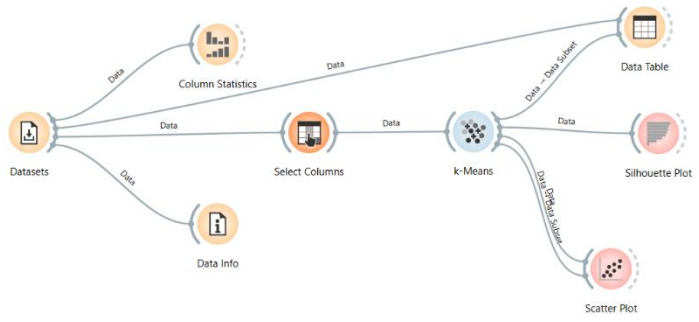

Pengaturan K-Means

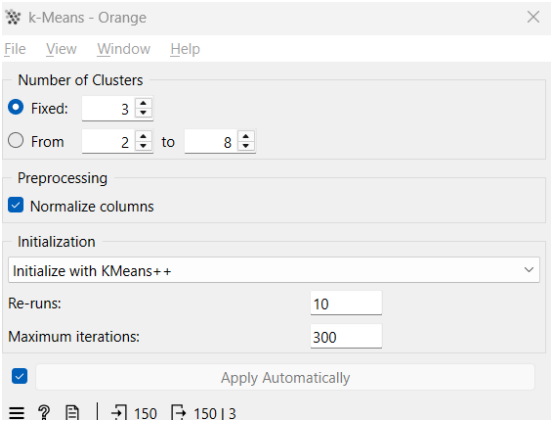

Pada metode K-Means, jumlah cluster ditetapkan sebanyak 3. Normalisasi kolom diaktifkan agar perbedaan skala antar fitur tidak memengaruhi hasil clustering. Inisialisasi menggunakan KMeans++, dengan 10 re-runs dan 300 maximum iterations agar hasil pengelompokan lebih stabil.

Hasil Silhouette Plot

Berdasarkan hasil Silhouette Plot, dataset Iris berhasil dibagi menjadi 3 cluster, yaitu C1, C2, danC3.
Nilai silhouette masing-masing cluster adalah:

- C1 = 0.448
- C2 = 0.658
- C3 = 0.384

Cluster C2 memiliki nilai silhouette tertinggi, sehingga merupakan cluster dengan pemisahan paling baik. Cluster C1 juga cukup baik, sedangkan C3 memiliki nilai paling rendah sehingga pemisahannya tidak sekuat cluster lainnya. Namun, karena mayoritas nilai silhouette tetap berada pada sisi positif, maka hasil clustering secara umum dapat dinilai cukup baik.

Hasil Scatter Plot

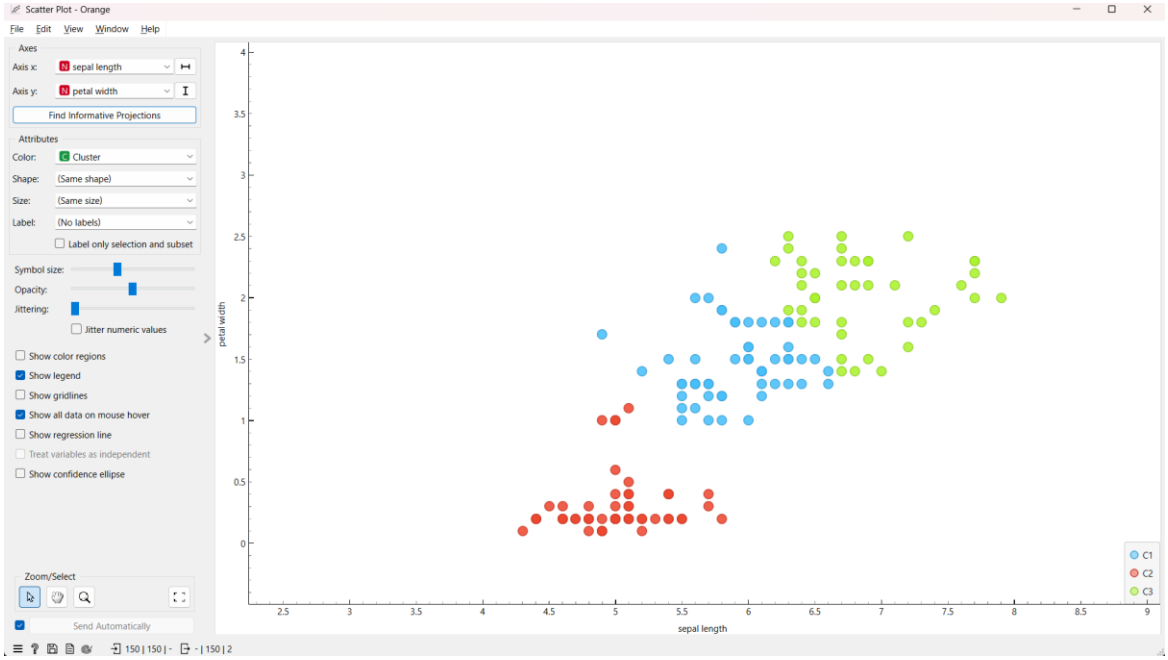

Pada visualisasi Scatter Plot, data berhasil terbagi menjadi tiga kelompok, yaitu C1, C2, dan C3. Salah satu cluster terlihat terpisah dengan cukup jelas, sedangkan dua cluster lainnya masih berada pada area yang relatif berdekatan. Hal ini menunjukkan bahwa metode K-Means cukup baik dalam mengelompokkan dataset Iris, meskipun masih terdapat sedikit overlap antar cluster.

Kesimpulan

Berdasarkan hasil clustering menggunakan K-Means, dataset Iris berhasil dikelompokkan menjadi 3 cluster. Nilai silhouette menunjukkan bahwa kualitas clustering cukup baik, dengan C2 sebagai cluster terbaik. Secara umum, metode K-Means sesuai digunakan untuk clustering dataset Iris pada percobaan ini.